

Notizen zu Algorithmen II

Jens Ochsenmeier

12. Februar 2018

Inhaltsverzeichnis

- 1 Stringology • 5
 - 1.1 Strings sortieren • 5
 - 1.2 Pattern Matching • 6
 - 1.3 Datenkompression • 13
- 2 Range Minimum Queries • 15
 - 2.1 Lösung 1 — $\langle O(n), O(\log n) \rangle$ • 16
 - 2.2 Lösung 2 — $\langle O(n \log n), O(1) \rangle$ • 16
 - 2.3 Lösung 3 — $\langle O(n \log \log n), O(1) \rangle$ • 17
 - 2.4 Lösung 4 — $\langle O(n), O(1) \rangle$ • 17
 - 2.5 Lowest Common Ancestor • 18
- 3 Burrows-Wheeler-Transformation • 23
 - 3.1 Konstruktion • 23
 - 3.2 Beobachtungen • 24
 - 3.3 Rücktransformation • 24
 - 3.4 Was bringt die BWT? • 27
 - 3.5 Kompression • 27
 - 3.6 Suche in der Burrows-Wheeler-Transformation • 28
 - 3.7 Wavelet Trees • 29
 - 3.8 Exkurs — Succinct Data Structures • 30
- 4 Geometrische Algorithmen • 35
 - 4.1 Grundlegende Definitionen • 35
 - 4.2 Streckenschnitte • 36
 - 4.3 Konvexe Hülle • 38
 - 4.4 Kleinste einschließende Kugel • 39
 - 4.5 Range Search • 39

5	Online-Algorithmen	• 41
5.1	Übersicht	• 41
5.2	Job-Scheduling	• 44
5.3	Skiausleihe	• 45
5.4	Speicherverwaltung	• 45
5.5	Auswahl von Experten	• 48

1

Stringology

Inhalt dieses Kapitels:

- Strings sortieren
- Patterns suchen
- Datenkompression

1.1 Strings sortieren

Naive Sortierv Verfahren, wie sie aus der Vorlesung “Algorithmen 1” bekannt sind, sind beim Sortieren von Strings ineffizient, deswegen gibt es für das Sortieren von Strings andere Algorithmen. Ein solcher ist der **Multikey Quicksort**-Algorithmus:

```
mkqsort (S: String Seq, l: N): String Seq
assert  $\forall e, e' \in S: e[1 \dots l - 1] = e'[1 \dots l - 1]$ 
if  $|S| \leq 1$  then return S
pick  $p \in S$  randomly
return concatenation of
  mkqsort ( $\{e \in S : e[l] < p[l]\}, l$ ),
  mkqsort ( $\{e \in S : e[l] = p[l]\}, l + 1$ ),
  mkqsort ( $\{e \in S : e[l] > p[l]\}, l$ )
```

Abbildung 1.1. Pseudocode-Implementierung des Multikey-Quicksort-Algorithmus.

Dieser Algorithmus sortiert eine String-Sequenz und nimmt an, dass die ersten $l - 1$ Buchstaben bereits sortiert wurden.

Zuerst wird ein zufälliges Pivotelement gewählt. Danach wird die übergebene Sequenz an Strings in drei Teilsequenzen geteilt:

1. Sequenz an Strings, deren l -ter Buchstabe kleiner ist als der l -te Buchstabe des Pivotelements.
2. Sequenz an Strings, deren l -ter Buchstabe derselbe ist wie der l -te Buchstabe des Pivotelements.
3. Sequenz an Strings, deren l -ter Buchstabe größer ist als der l -te Buchstabe des Pivotelements.

Auf die erste und dritte Teilsequenz wird der Algorithmus nun rekursiv mit dem selben Parameter l ausgeführt, da die Buchstaben an der l -ten Position nicht übereinstimmen (müssen) — auf die zweite Teilsequenz wird der Algorithmus rekursiv mit dem Parameter $l + 1$ ausgeführt, weil hier die l -ten Buchstaben aller Wörter in der Sequenz gleich sind.

Die Laufzeit des Algorithmus ist in $O(|S| \log |S| + d)$, wobei d die Summe der eindeutigen Präfixe der Strings in S ist.

1.2 Pattern Matching

Hinweis: In diesem Abschnitt sind Arrays 1-basiert.

In diesem Abschnitt wird es darum gehen, alle oder zumindest ein Vorkommen eines **Patterns** $P = p_1 \dots p_m$ in einem gegebenen **Text** $T = t_1 \dots t_n$ zu finden. Im Allgemeinen ist $n \gg m$, also der Text wesentlich länger als das Pattern, das wir in ihm suchen.

Naives Pattern Matching

Das naive Vorgehen ist, an jeder Position von T zu schauen, ob an dieser das gesuchte Pattern vorkommt. Offensichtlich ist dieser Algorithmus in $O(nm)$, da im schlimmsten Fall für jede Position des Textes das gesamte Pattern durchlaufen werden muss. Dieser Algorithmus kann folgendermaßen implementiert werden:

```

NAIVEPATTERNMATCH (P, T)
i, j := 1
while i ≤ n - m + 1
  while j ≤ m ∧ ti+j-1 = pj do j++
  if j > m then return "P occurs at pos i in T"
  i++
  j := 1

```

Abbildung 1.2. Pseudocode-Implementierung des naiven Pattern-Matching-Algorithmus.

Knuth-Morris-Pratt

Ein anderer Algorithmus zum Finden von Patterns in einem gegebenen Text ist der **Knuth-Morris-Pratt-Algorithmus**. Dieser hat sogar optimale Laufzeit, nämlich $O(n + m)$.

Idee dieses Algorithmus ist es, das Pattern eleganter nach vorne zu verschieben, wenn es einen Mismatch zwischen Text und Pattern gibt. Hierfür brauchen wir ein Hilfswerkzeug:

Für einen String S mit Länge k sei $\alpha(S)$ die Länge des Längsten Präfixes von $S_{1\dots k-1}$, das auch Suffix von $S_{2\dots k}$ ist.¹




Abbildung 1.3. Idee beim Verschieben des Patterns: α wurde bereits gematcht. Früher als mit dem bereits gematchten Suffix kann das nächste Vorkommen von P nicht auftauchen, also kann man P direkt um $j - 1 - \alpha$ verschieben.

Der Algorithmus besteht aus zwei Teilen:

1. **Border-Array berechnen** ($O(m)$). Damit die oben erläuterten Verschiebungen nachher effizient durchgeführt werden können, berechnen wir für das leere Wort

¹ Wir lassen absichtlich bei Betrachtung des Präfixes den letzten und bei Betrachtung des Suffixes den ersten Buchstaben weg, damit $\alpha(S) = 0$ ist, wenn $|S| = k = 1$ ist.

und jeden Buchstaben in P einen α -Wert. Diese Werte ergeben das **Border-Array**:

$$\text{border}[j] = \begin{cases} -1, & \text{falls } j = 1 \\ \alpha(P_{1\dots j-1}), & \text{sonst} \end{cases}$$

Abbildung 1.4. Beispiel für das Border-Array eines Patterns.

2. **Pattern matchen** ($O(n)$). Nun verwenden wir das erstellte Border-Array, um Vorkommnisse von P in T zu finden. Wir starten sowohl im Text als auch im Pattern an Position 1 und fangen an zu matchen. Kommt es an Position $1 \leq j \leq m$ des Patterns zu einem Mismatch, so können wir P direkt um $j - \text{border}[j] - 1$ verschieben. In Pseudocode sieht das so aus:

```
KMPMATCH (P,T)
i, j := 1
while i ≤ n - m + 1
  while j ≤ m ∧ ti+j-1 = pj do j++
  if j > m then return "P occurs at pos i in T"
  i += j - border[j] + 1
  j := max{1, border[j] + 1}
```

Eine Ausführung des Algorithmus kann also folgendermaßen aussehen:

Beispiel: $T = \text{a a h a a a h a n a q}$
 $P = \text{a n a q}$
 $\text{border} = [-1, 0, 0, 1, 2, 3, 0]$

Abbildung 1.5. Beispiel für das Verwenden des Knuth-Morris-Pratt-Algorithmus.

Suffix-Arrays

Im Folgenden werden Arrays wieder mit Position 0 beginnen. Wir verwenden desweiteren folgende Festlegungen:

- Ein **String** ist ein Array von Buchstaben,

$$S[0 \dots n] := S[0 \dots n - 1] := [S[0], \dots, S[n - 1]].$$

- Das **Suffix** S_i sei der Substring $S[i \dots n]$ von S .

- Wir setzen an das Ende jedes Strings ausreichend viele **Endmarkierungen**:
 $S[n] := S[n+1] := \dots := 0$. 0 sei per Definition kleiner als alle anderen vorkommenden Zeichen.

Das **Suffix-Array** eines Strings lässt sich nun folgendermaßen konstruieren:

- Bilde die Menge aller Suffixe S_i ($i = 0, \dots, n-1$) des Strings.
- Sortiere die Menge aller Suffixe des Strings (z.B. mit **Multikey Quicksort**).

0	banana	5	a
1	anana	3	ana
2	nana	1	anana
3	ana	0	banana
4	na	4	na
5	a	2	nana

Abbildung 1.6. Beispiel für die Konstruktion des Suffix-Arrays des Strings "banana".

Mithilfe dieses Suffix-Arrays lassen sich später viele Suchprobleme in Linearzeit lösen. Beispielsweise ist die Suche nach dem längsten Substring, der (eventuell mit Überschneidung) zweimal im Text vorkommt, linear — dafür muss nach Berechnung des Suffix-Arrays der längste String gefunden werden, der Präfix von zwei Strings im Suffix-Array ist (im Beispiel oben wäre das "ana").

Berechnung des Suffix-Arrays in Linearzeit

Das Suffix-Array eines Strings lässt sich in Linearzeit berechnen.² Hier soll lediglich das Prinzip erläutert werden, genauere Angaben gibt es im Paper.

Wir betrachten den String

$$T[0, n) = \underset{\substack{0 \\ x}}{\underset{1}{a}} \underset{2}{b} \underset{3}{b} \underset{4}{a} \underset{5}{d} \underset{6}{a} \underset{7}{b} \underset{8}{b} \underset{9}{a} \underset{10}{d} \underset{11}{o}.$$

Unser Ziel ist das Suffix-Array

$$SA = (12, 1, 6, 4, 9, 3, 8, 2, 7, 5, 10, 11, 0).$$

Wir gehen wie folgt vor:

0. **Suffixe wählen.** Sei

$$B_k = \{i \in [0, n] : i \bmod 3 = k\}$$

und $C = B_1 \cup B_2$ sowie S_C die Menge der entsprechenden Suffixe. C ist also die Menge aller Positionen in T , an denen Suffixe mit einer nicht durch 3 teilbaren Länge beginnen. Hier ist $C = \{1, 4, 7, 10, 2, 5, 8, 11\}$.

² Kärkkäinen, Sanders, Burkhardt: Linear Work Suffix Array Construction

1. **Gewählte Suffixe sortieren.** Wir fügen am Ende von T beliebig viele \emptyset hinzu und bilden zuerst für $k = 1, 2$ die Strings

$$R_k = [t_k t_{k+1} t_{k+2}] [t_{k+3} t_{k+4} t_{k+5}] \cdots [t_{\max B_k} t_{\max B_k+1} t_{\max B_k+2}].$$

Der Charaktere von R_k sind also Tripel. Das letzte Tripel ist immer eindeutig, weil $t_{\max B_k+2} = 0$. Sei $R = R_1 \odot R_2$.

Hier ist

$$R = [\text{abb}][\text{ada}][\text{bba}][\text{do}\emptyset][\text{bba}][\text{dab}][\text{bad}][\text{o}\emptyset\emptyset].$$

Die Ordnung der Suffixe von R stimmt mit der Ordnung der Suffixe S_i überein, deswegen genügt es, die Suffixe von R zu sortieren.

Wir sortieren R nun, indem wir die einzelnen Charaktere von R sortieren und durch ihren Rang in R ersetzen:

$$\text{SA}_R = (8, 0, 1, 6, 4, 2, 5, 3, 7).$$

Nun weisen wir jedem Suffix einen Rang zu. Dazu sei $\text{rank}(S_i)$ der Rang von S_i in C . Für $i \in B_0$ sei $\text{rank}(S_i)$ nicht definiert.

Hier ist $\text{rank}(S_i) = \perp \ 1 \ 4 \ \perp \ 2 \ 6 \ \perp \ 5 \ 3 \ \perp \ 7 \ 8 \ \perp \ 0 \ 0$.

2. **Restliche Suffixe sortieren.** Jeder Suffix $S_i \in S_{B_0}$ sei dargestellt durch $(t_i, \text{rank}(S_{i+1}))$. Da wir alle anderen Suffixe oben schon sortiert haben ist $\text{rank}(S_{i+1})$ hier stets definiert.

Offensichtlich ist

$$S_i \leq S_j \Leftrightarrow (t_i, \text{rank}(S_{i+1})) \leq (t_j, \text{rank}(S_{j+1})),$$

also lassen sich die Paare Radix-sortieren.

Hier ist

$$S_{12} < S_6 < S_9 < S_3 < S_0, \quad \text{weil} \quad (\emptyset, 0) < (a, 5) < (a, 7) < (b, 2) < (x, 1).$$

3. **Zusammenführen.** Das Zusammenführen erfolgt vergleichsbasiert. Beim Vergleichen on $S_i \in S_C$ mit $S_j \in S_{B_0}$ unterscheiden wir zwei Fälle:

$$i \in B_1 : S_i \leq S_j \Leftrightarrow (t_i, \text{rank}(S_{i+1})) \leq (t_j, \text{rank}(S_{j+1}))$$

$$i \in B_2 : S_i \leq S_j \Leftrightarrow (t_i, t_{i+1}, \text{rank}(S_{i+2})) \leq (t_j, t_{j+1}, \text{rank}(S_{j+2}))$$

Hier ist z.B. $S_1 < S_6$ weil $(a, 4) < (a, 5)$ und $S_3 < S_8$ weil $(b, a, 6) < (b, a, 7)$.

Suchen in Suffix-Arrays

Um ein Pattern in einem String zu finden, zu dem man das Suffix-Array konstruiert hat, muss man lediglich ein Suffix finden, dass das gesuchte Pattern als Präfix hat. Man kann so beispielsweise mit binärer Suche in $O(m \log n)$ ein Vorkommen von P in T finden.

Nutzen wir eine zusätzliche Struktur, das **LCP-Array** — dieses speichert in $LCP[i]$ die Länge des längsten gemeinsamen Präfixes von $SA[i]$ und $SA[i - 1]$ — so können wir die Suchzeit auf $O(m + \log n)$ reduzieren.

0	banana		5	a		0	a
1	anana		3	ana		1	a na
2	nana		1	anana		3	an ana
3	ana	SA =	0	banana	LCP =	0	banana
4	na		4	na		0	na
5	a		2	nana		2	na na

Abbildung 1.7. Suffixe, Suffix-Array und LCP-Array des Strings "banana".

Um das LCP-Array berechnen zu können brauchen wir das **invertierte Suffix-Array**. Dieses gibt Aufschluss darüber, wo im Suffix-Array ein bestimmter Suffix steht. Offensichtlich ist $SA^{-1}[SA[i]] = i$.

Der Algorithmus sieht folgendermaßen aus ($O(n)$):

```

CALCULATELCPARRAY ( $SA^{-1}$ , SA)
 $h := 0$ ,  $LCP[1] := 0$ 
for  $i = 1, \dots, n$  do
  if  $SA^{-1}[i] \neq 1$  then
    while  $t_{i+h} = t_{SA[SA^{-1}[i]-1]+h}$  do  $h++$ 
     $LCP[SA^{-1}[i]] := h$ 
     $h := \max(0, h - 1)$ 

```

Suffix-Bäume

Noch anschaulicher, allerdings wesentlich platzverbrauchender, sind **Suffix-Bäume** von Strings. Sie sind formal der *komprimierte Trie der Suffixe* und lassen sich (wenn auch sehr kompliziert) in $O(n)$ berechnen.

Bevor wir den Suffix-Baum eines Strings bilden hängen wir hinten an den String noch einen Charakter dran, der nicht im Alphabet des Strings vorkommt. Das hat den Vorteil, dass anschließend alle Suffixe in einem Blatt des Baums enden.




Abbildung 1.8. Beispiel für den Suffix-Baum des Strings "banana".

"Naiv" ist die Erstellung des Suffixbaums in $O(n^2)$. Man kann ihn aber auch aus Suffix-Array und LCP-Array in Linearzeit konstruieren. Dazu hängt man die Suffixe sukzessive in der Tiefe ein, die ihr LCP-Wert angibt:




Abbildung 1.9. Sukzessive Konstruktion des Suffix-Baums aus Suffix- und LCP-Array. Zuerst hängt man \$ und das erste Suffix (dessen LCP-Wert immer 0 ist) an die Wurzel. Anschließend nutzt man den LCP-Wert des darauffolgenden Suffixes (hier 1), um festzulegen, wo der Suffix zum Baum hinzugefügt werden muss (durch Pfeile gekennzeichnet).

Die Suche in einem Suffix-Baum ist relativ simpel — man muss lediglich den entsprechenden Kanten entlanglaufen, alle Vorkommen des Patterns liegen im entsprechenden Teilbaum.

Zur Angabe der Komplexitäten sind zwei Fälle zu unterscheiden:

1. Die ausgehenden Kanten sind als Arrays der Größe $|\Sigma|$ gespeichert. Dann ist die Suchzeit in $O(m)$ und der Gesamtplatzbedarf in $O(n|\Sigma|)$.
2. Die ausgehenden Kanten sind als Arrays gespeichert, deren Größe proportional zur Anzahl der Kinderknoten ist. Dann ist die Suchzeit in $O(m \log |\Sigma|)$ und der Gesamtplatzbedarf in $O(n)$.

1.3 Datenkompression

Eine Anwendung der Suffix-Arrays und -Trees ist die **Datenkompression**. Inhalt dieser Vorlesung wird ausschließlich die *verlustfreie Textkompression* sein.

Wörterbuchbasierte Textkompression

Für besonders große Datenbestände bietet sich eine **wörterbuchbasierte Textkompression** an. Grundidee ist, $\Sigma' \subseteq \Sigma^*$ zu wählen und $S \in \Sigma^*$ durch $S' = \langle s'_1, \dots, s'_k \rangle \in \Sigma'^*$ zu ersetzen, sodass $S = s'_1 \cdot \dots \cdot s'_k$ ist. Problem ist der hohe zusätzliche Platzbedarf für das Wörterbuch.

Lempel-Ziv-Kompression

Die **Lempel-Ziv-Kompression** baut das Wörterbuch *on the fly* bei Codierung und Decodierung, sodass dieses nicht explizit gespeichert werden muss.

```

NAIVELZCOMPRESS( $\langle s_1, \dots, s_n \rangle, \Sigma$ )
 $D := \Sigma$  // init dictionary
 $p := s_1$  // current string
for  $i := 2$  to  $n$  do
  if  $p \cdot s_i \in D$  then  $p := p \cdot s_i$ 
  else
    output code for  $p$ 
     $D := D \cup p \cdot s_i$ 
     $p := s_i$ 
output code for  $p$ 

```

```

NAIVELZDECODE( $\langle c_1, \dots, c_k \rangle$ )
 $D := \Sigma$ 
output decode( $c_1$ )
for  $i := 2$  to  $k$  do
  if  $c_i \in D$  then
     $D := D \cup \text{decode}(c_{i-1}) \cdot \text{decode}(c_i)[1]$ 
  else
     $D := D \cup \text{decode}(c_{i-1}) \cdot \text{decode}(c_{i-1})[1]$ 
  output decode( $c_i$ )

```

Abbildung 1.10. Kompressions- und Dekodierungs-Algorithmus für die Lempel-Ziv-Kompression.




Abbildung 1.11. Beispiel für das Bilden der Lempel-Ziv-Kompression des Wortes "abracadabra". Der Baum wird *on the fly* berechnet und nicht übergeben, sondern nur die komprimierte Information und das Alphabet.

2

Range Minimum Queries

Eine **range minimum Query** gibt für ein array A ($|A| = n$) die Position des kleinsten Elements zwischen zwei Begrenzern $1 \leq l < r \leq n$ zurück:

$$\text{rmq}_A(l, r) = (\arg) \min_{l \leq k \leq r} A[k]$$




Abbildung 2.1. Beispiel einer range minimum query.

Ziel dieses Kapitels wird sein, einen Algorithmus anzugeben, mit dem eine RMQ-Abfrage in konstanter Zeit beantwortet werden kann, nachdem eine $2n + o(n)$ große Datenstruktur in Linearzeit vorbereitet wurde.

Ein naiver Ansatz, um eine range minimum query auszuführen, ist, einfach das Array zu durchlaufen und das Minimum zu speichern (und wenn nötig zu aktualisieren). Dafür ist keine Vorbereitungsarbeit nötig (also $O(1)$) und die Abfrage ist in $O(n)$. Wir notieren

$$\langle O(1), O(n) \rangle.$$

2.1 Lösung 1 — $\langle O(n), O(\log n) \rangle$

Baut man einen binären Suchbaum über das Array auf, so lässt sich die Komplexität der Abfrage auf $O(\log n)$ reduzieren.

Hierzu betrachtet man die größtmöglichen Knoten, die vollständig im Abfrageintervall liegen (grün dargestellt), und berechnet das Minimum dieser.




Abbildung 2.2. Die grauen Felder stellen die Knoten des binären Suchbaums dar, sie beinhalten die Position des Arrays, an der der Teilbaum, dessen Wurzel sie sind, den minimalen Wert annimmt. Die größten Knoten, die vollständig im Intervall liegen, sind grün markiert..

2.2 Lösung 2 — $\langle O(n \log n), O(1) \rangle$

Wir reduzieren nun die Zeit, die zum Bearbeiten der rmq benötigt wird, auf $O(1)$, indem wir für jedes $A[i]$ ein Array $M_i[0, \log n]$ vorberechnen. Es sei

$$M_i[j] = rmq_A(i, i + 2^j - 1).$$

Idee ist es nun, $rmq_A(l, r)$ aus der Überdeckung des Intervalls durch zwei Zweierpotenzen zu berechnen.

Wir suchen dafür $2^{\lfloor l-r \rfloor}$, also die größte Zweierpotenz, die kleiner ist als die Länge des Intervalls. Offensichtlich ist diese Zweierpotenz mehr als halb so groß wie das Intervall, also ist $rmq_A(l, r)$ entweder das Minimum der ersten oder zweiten überdeckenden Zweierpotenz.




Abbildung 2.3. Funktionsweise des zweiten rmq-Algorithmus.

2.3 Lösung 3 — $\langle O(n \log \log n), O(1) \rangle$

Wir wenden folgende Prozedur an:

1. A in $t = \frac{n}{\log n}$ Blöcke B_0, \dots, B_{t-1} der Größe $\log n$ unterteilen.
2. Array $S[0, t-1]$ mit $S[i] = \min \{x \in B_i\}$ erstellen, rmq-Struktur nach Lösung 2 für S berechnen.
3. Für jeden Block B_i rmq-Struktur nach Lösung 2 berechnen.

Diese Prozedur liegt in $O(n \log \log n)$.

Soll nun $\text{rmq}_A(l, r)$ bestimmt werden, so geht das folgendermaßen:

1. Bestimme die Blöcke $l \in B_{l'}$ und $r \in B_{r'}$.
2. Berechne $m = \text{rmq}_S(l' + 1, r' - 1)$. Wir nutzen also die Struktur über S , um die rmq-Werte der Blöcke zwischen den beiden Grenzblöcken zu berechnen.
3. Es seien k_0, k_1, k_2 die rmq_A -Resultate in den Blöcken l', r' und m .
4. $\text{rmq}_A(l, r) = \arg \min \{A[k_0], A[k_1], A[k_2]\}$.

2.4 Lösung 4 — $\langle O(n), O(1) \rangle$

Zur Konstruktion des Algorithmus mit linearem Platzverbrauch benötigen wir kartesische Bäume.

Kartesischer Baum

Der **kartesische Baum** eines Arrays A ist folgendermaßen definiert:

- Wurzel des Baums ist das (linkste) kleinste Element m des Arrays, mit Position als Label.

- Die Wurzel hat zwei Kindknoten — die Wurzel des linken und die Wurzel des rechten Subarrays von A (jeweils von m aus).
- Rekursion.

Implementierung

Die Implementierung funktioniert so:

1. Partitioniere das Array in Blöcke der Größe s — jeder Block entspricht einem kartesischen Baum.
2. Berechne alle s^2 Möglichkeiten aller $\frac{1}{s+1} \binom{2s}{s}$ möglichen kartesischen Bäume der Größe s in einer Tabelle P . Diese benötigt $O(2^{2s} s^2)$ Speicher, also braucht P für $s = \frac{\log n}{4}$ nur $o(n)$ Speicher.
3. Berechne nach Lösung 2 die Struktur für das Array A' , welche aus den blockweisen Minima von A besteht ($O(n)$ Zeit, $O(n)$ Platz).

2.5 Lowest Common Ancestor

Gegeben sei ein Baum T mit Wurzel, $|T| = n$. Es sei

$$\text{LCA}_T(v, w)$$

der **lowest common ancestor** der Knoten v, w in T , also der Knoten $a \in T$, der

- Vorgänger von v und w ist und
- maximalen Abstand zur Wurzel hat.




Abbildung 2.4. lowest common ancestor der Knoten h und j ist e .

Von RMQ zu LCA

Lemma 2.5.1. Gibt es eine $\langle f(n), g(n) \rangle$ -Lösung für RMQ, so gibt es eine Lösung in

$$\langle f(2n-1) + O(n), g(2n-1) + O(1) \rangle$$

für LCA.

Beweis. Sei

- T der kartesische Baum des Arrays A ,
- $E[0, \dots, 2n-2]$ das Knoten-Array, die in einer DFS-Euler-Tour von T besucht wurden,
- $L[0, \dots, 2n-2]$ die entsprechende Tiefe der Knoten in E ,
- $R[0, \dots, n-1]$ ein Array mit $R[i] = \min \{j : E[j] = i\}$ für jeden Knoten $i \in T$, also wo in der Euler-Tour der Knoten i das erste Mal auftaucht.

Dann ist

$$\text{LCA}_T(v, w) = E[\text{RMQ}_L(\min \{R[v], R[w]\}, \max \{R[v], R[w]\})].$$

□




Abbildung 2.5. Konstruktion der Hilfsarrays für LCA.

Achtung: Die Tiefe zweier Knoten, die nacheinander bei der Euler-Tour besucht wurden, kann sich höchstens um 1 unterscheiden, also

$$(L[i] - L[i+1]) \in \{-1, 1\}.$$

Wir müssen also nur RMQs über Arrays lösen, bei denen sich zwei nacheinanderfolgende Elemente um 1 unterscheiden. Das ist das sogenannte **± 1 -RMQ**.

Wir werden nun im Folgenden ausnutzen, dass wir zum Lösen des LCA-Problems nur ± 1 -RMQs betrachten müssen.

LCA in $\langle O(n), O(1) \rangle$ auf $4n + o(n)$ Bits

Wir verwenden folgende Konstruktion:

Wir können nun den RMQ-Wert folgendermaßen berechnen:

```

RMQ (A, l, r)
  lpos := select(l + 1, (), BPext)
  rpos := select(r + 1, (), BPext)
  return rank(rmqexcess±1(lpos, rpos + 1), (), BPext)

```

LCA in $\langle O(n), O(1) \rangle$ auf $2n + o(n)$ Bits

Die Anzahl an benötigten Bits lässt sich im Vergleich zum vorhergehenden Ansatz noch weiter verkleinern. Wir transformieren dazu den kartesischen Baum — der ja ein Binärbaum ist — in einen allgemeinen Baum. Dazu gehen wir folgendermaßen vor:

1. Füge einen Elternknoten zur Wurzel des Baums hinzu (der hinzugefügte Knoten ist also die neue Wurzel).
2. Nehme von jedem Knoten v — von der neuen Wurzel ausgehend — den rechten Kindknoten w , und füge alle Knoten auf dem linken Pfad von w ausgehend zu den Kindknoten von v hinzu.




Abbildung 2.7. Kartesischer Baum mit neuer Wurzel. Die roten Knoten in der ersten Grafik sind die Knoten, die zu v — hier die neue Wurzel — hinzugefügt werden. Durch Hinzufügen dieser Knoten zu den Kindknoten von v hat der Baum die Struktur in Grafik 2. Nun wird dieser Prozess rekursiv auf die drei roten Knoten ausgeführt. Ist die Rekursion vollständig abgeschlossen sieht der Baum wie in der dritten Grafik aus.

Diese Transformation lässt sich bei Bedarf auch rückgängig machen; man kann also, wenn nötig, wieder den Binärbaum konstruieren.

Nun lässt sich wieder die Klammernreihe BP von oben bauen. Mit dieser können wir nun RMQ-Abfragen lösen:

```

RMQ (A, l, r)
  lpos := select(l + 2, (), BP)
  rpos := select(r + 2, (), BP)
  return rank(rmqexcess±1(lpos - 1, rpos), (), BP) - 1

```


3

Burrows-Wheeler-Transformation

Die **Burrows-Wheeler-Transformation** erzeugt eine sinnvolle Permutation des eingegebenen Strings; sie gruppiert Zeichen mit ähnlichem Kontext nahe beieinander. Die Struktur der Permutation beinhaltet alle Informationen, die benötigt werden, um eine Rücktransformation durchzuführen, es sind also keine Zusatzinformationen nötig. Hin- und Rücktransformation geht in $O(n)$. Sie wird hauptsächlich zur Vorverarbeitung statischer Texte genutzt, um sie komprimieren, indizieren und in ihnen suchen zu können.

3.1 Konstruktion

Sei $T = \text{lalalangan}\$$ der gegebene String (mit angehängtem $\$$ -Zeichen), $n = |T|$ und $T^{(i)}$ die i -te Permutation von T (durch i mal den vordersten Buchstaben nehmen und hinten anhängen). Man erhält die Burrows-Wheeler-Transformation von T so:

1. Schreibe $T^{(1)}$ bis $T^{(n)}$ untereinander.
2. Sortiere $T^{(1)}$ bis $T^{(n)}$.
3. Die letzte Spalte ist T^{BWT} ($= L$), die Burrows-Wheeler-Transformation von T .

3 Burrows-Wheeler-Transformation




Abbildung 3.1. Konstruktion der Burrows-Wheeler-Transformation von $T = \text{lalalangng\$}$, $T^{BWT} = \text{gl1nn\$ aga}$. Da T^{BWT} die letzte Spalte ist schreibt man oft auch L stattdessen. Die erste Spalte wird auch F genannt.

Naiv benötigt die Berechnung von T^{BWT} $O(n^2 + n \log n)$ Schritte. Die Berechnungszeit lässt sich aber auf $O(n)$ reduzieren.

3.2 Beobachtungen

Folgende Eigenschaften lassen sich feststellen:


- Die Zeilen der oben konstruierten Matrix enthalten die sortierten Suffixe von T (vom Zeilenstart bis $\$$ gehend).
- Die Zeichen der letzten Spalte (also T^{BWT}) sind also die Zeichen, die vor dem zu ihrer Zeile gehörenden Suffix stehen. Formaler ist $T^{BWT}[i]$ das Zeichen vor dem i -ten Suffix in T :

$$T^{BWT}[i] = L[i] = T[\text{SA}[i] - 1] = T^{(\text{SA}[i])}[n]$$

Da wir mithilfe des **DC3-Algorithmus** das Suffix-Array in Linearzeit berechnen können, können wir auch die Burrows-Wheeler-Transformation in Linearzeit bestimmen.

3.3 Rücktransformation

Wir können aus einer vorliegenden T^{BWT} einfach F — also die erste Spalte der Matrix — konstruieren, indem wir die Buchstaben von T^{BWT} sortieren. Hängen wir nun T^{BWT} und F hintereinander, so haben wir bereits Buchstabenpaare, die so auch in T auftreten. Sortieren wir nun die beiden Spalten (also die Buchstabenpaare) lexikographisch, so erhalten wir die auf F folgende Spalte. Durch diesen Prozess lässt sich die gesamte Matrix und somit T rekonstruieren.



Diese Art der Rücktransformation benötigt $O(n^2 \log n)$ Schritte. Im Folgenden werden wir die Rücktransformation auf Linearzeit reduzieren. Dazu benötigen wir **Last-to-front mapping**:

$\text{LF}[i] :=$ Position in L , an der Vorgänger von $L[i]$ steht

Da die Spalten der BWT-Matrix zyklisch sind, ist der Vorgänger von $L[i]$ derjenige Buchstabe, der in $F[i]$ steht, also


$$\text{LF}[i] = \text{Position, an der } L[i] \text{ in } F \text{ steht}$$


Abbildung 3.2. Gesucht ist der Vorgänger von $\$$. Stellen wir uns T^{BWT} ein zweites Mal links von F vor, so sehen wir, dass es g ist.

Wir erhalten folgenden Zusammenhang:

$$\text{LF}[i] = j \Leftrightarrow T^{(\text{SA}[j])} = \left(T^{(\text{SA}[i])}\right)^{(n)}.$$

Weitere Überlegungen zur Rücktransformation

Wir können desweiteren folgende Beobachtungen an T^{BWT} machen:

- Gleiche Zeichen haben gleiche Reihenfolge in F und L .
- Falls $L[i] = L[j]$ für $i < j$, dann ist $\text{LF}[i] < \text{LF}[j]$.

Grund dafür ist, dass die Zeilen der BWT-Matrix lexikographisch sortiert sind.




Abbildung 3.3. Präfixe α und β und wie sie in der Matrix vorkommen.

Wir können also LF rein aus T^{BWT} berechnen. Dazu brauchen wir nur zwei Hilfsfunktionen:

- $C(a) := \# \text{ Zeichen} < a$
- $\text{occ}[i] := \# \text{ Zeichen} = L[i] \text{ in } L[1 \dots i]$

Nun können wir $LF[i]$ darstellen als

$$LF[i] = C(L[i]) + \text{occ}[i]$$

und können somit LF in $O(n)$ berechnen, da sich C und occ in Linearzeit berechnen lassen.

Implementierung

Zuerst berechnen wir LF. Hier sieht die Implementierung so aus:

1. Initialisiere occ und h . h sei ein Array, das zählt, wie oft ein bestimmter Buchstabe vorkommt, damit wir nachher C gescheit berechnen können.
2. Laufe durch $L = T^{BWT}$ ($i = 1 \dots n$)
 - $h(L[i])++$
 - $\text{occ}(L[i]) = h(L[i])$
3. Konstruiere C aus h : $C(\$) = 0$, $C(\alpha) = C(\alpha - 1) + h(\alpha - 1)$ (α ist ein Buchstabe, $\alpha - 1$ sein Vorgänger)
4. $LF[i] = C(L[i]) + \text{occ}[i]$





Abbildung 3.4. Beispiel des Algorithmus zur Berechnung von LF nach Durchführung.

Nun kann T von rechts nach links berechnet werden:

1. $T[n] = \$ \Rightarrow LF[\cdot] = 1$. Das ist unabhängig von T so.
2. $L[1] = \text{g} \Rightarrow T[n - 1] = \text{g} \Rightarrow LF[1] = 4$
3. $L[4] = \text{n} \Rightarrow T[n - 2] = \text{n} \Rightarrow \dots$

Also geht auch die Rücktransformation in $O(n)$.



3.4 Was bringt die BWT?

Die Vorteile der Burrows-Wheeler-Transformation sind nicht direkt erkennbar — sie nutzt dieselben Zeichen wie T und benötigt den gleichen Platz.

Allerdings wird die *Komprimierung stark vereinfacht*, weil Zeichen mit ähnlichem Kontext gruppiert werden. Besonders gut funktioniert sie auf Texten mit vielen gleichen Substrings, wie beispielsweise einem englischen Fließtext. Zur Vereinfachung von *Indexierung* und *Suche* steuert sie auch bei, weil Vorgänger von Suffixen einfach bestimmt werden können.

Im Folgenden werden wir uns die Burrows-Wheeler-Transformation im Kontext von *Kompression* und *Suche* anschauen.

3.5 Kompression

Wir schauen uns zwei Kompressionsmöglichkeiten an: die *move to front*-Kodierung und die Huffman-Kodierung

MTF-Kodierung

Idee der **MTF-Kodierung** ist es, lokale Redundanz zu nutzen und so kleine Zahlen für gleiche Zeichen, die nahe beieinander liegen, zu verwenden. Die Umsetzung funktioniert so:

1. Initialisiere Y mit Alphabet von T^{BWT} .
2. Durchlaufe T^{BWT} ($i = 1, \dots, n$)
 - Generiere $R[1, \dots, n]$, wobei $R[i]$ die Position von $T^{\text{BWT}}[i]$ in Y codiert.
 - Schiebe $T^{\text{BWT}}[i]$ an den Anfang von Y .

$T^{\text{BWT}} = \overset{1}{\text{g}} \overset{2}{\text{l}} \overset{3}{\text{l}} \overset{4}{\text{n}} \overset{5}{\text{n}} \overset{6}{\text{a}} \overset{7}{\text{g}} \overset{8}{\text{a}} \overset{9}{\$}$ $R = 3 \ 4$	<table style="border: none;"> <tr> <td style="text-align: center; padding-right: 5px;">1 2 3 4 5</td> <td></td> </tr> <tr> <td style="text-align: center;">\$ a g l n</td> <td></td> </tr> <tr> <td style="text-align: center;">g \$ a l n</td> <td></td> </tr> <tr> <td style="text-align: center;">Y = 1 g \$ a n</td> <td></td> </tr> </table>	1 2 3 4 5		\$ a g l n		g \$ a l n		Y = 1 g \$ a n	
1 2 3 4 5									
\$ a g l n									
g \$ a l n									
Y = 1 g \$ a n									

Abbildung 3.5. Es wurde hier gerade die 4 eingefügt und deswegen 1 in Y nach vorne genommen. Als nächstes muss 1 codiert ($\cong 1$) und Y anschließend nicht verändert werden, weil 1 ja eh schon ganz vorne steht.

Huffman-Kodierung

Die **Huffman-Kodierung** erzeugt präfixfreie Codes variabler Länge. Der Ablauf ist:

1. Notiere vorkommende Symbole und ihre jeweiligen Häufigkeiten. Sie sind die Blätter des (binären) Huffman-Baumes.
2. Verknüpfe die zwei seltensten Knoten in einem neuen Knoten. Die Häufigkeit des neuen Knotens ist die Summe der Häufigkeiten seiner Kinder. Dies erfolgt nun iterativ.
3. Die Wurzel hat relative Häufigkeit 1 (bzw. absolute Häufigkeit $|T|$).
4. Beschrifte die Kanten zwischen einem Knoten und seinen beiden Kindern mit 0 und 1. Der Pfad von der Wurzel zu einem bestimmten Blatt ergibt den Code des Symbols, zu dem das Blatt gehört.




Abbildung 3.6. MTF-Kodierung R von T , die Häufigkeit der in R vorkommenden Symbole und die mit dem Huffman-Baum erzeugten Codes.

3.6 Suche in der Burrows-Wheeler-Transformation

Wir möchten nun in T^{BWT} nach einem Pattern P suchen. Hier sei

$P = \text{bar}$ und

$T = \text{abracadabrabarbara\$}$ und somit

$\text{BWT} = \text{arrd\$rcbbraaaaabba}$

Wir benötigen dazu zwei Hilfsmittel:

- Das Array C beinhalte für jeden eindeutigen Buchstaben in $t \in T$ die Position des ersten Suffixes im Suffix-Array, das mit t beginnt.

- $\text{rank}(i, X, \text{BWT})$ gibt an, wie oft ein Buchstabe X in $\text{BWT}[0, \dots, i - 1]$ vorkommt.

Wir suchen nun nach P in BWT. Wir suchen rückwärts, starten also mit “r”. Dazu ermitteln wir alle Suffixe, die mit r starten. Wir nutzen dazu C und rank:

- Initiales Intervall: $[\text{sp}_0, \text{ep}_0] = [0, \dots, n - 1]$.
- Ermittle Intervall der Suffixe, die mit r starten:
 - $\text{sp}_1 = C[r] + \text{rank}(\text{sp}_0, r, \text{BWT}) = 15 + \text{rank}(0, r, \text{BWT}) = 15 + 0 = 15$
 - $\text{ep}_1 = C[r] + \text{rank}(\text{ep}_0 + 1, r, \text{BWT}) - 1 = 15 + 4 - 1 = 18$

Wir suchen nun analog nach “ar”, indem wir sp_2 und ep_2 aus sp_1 und ep_1 berechnen. Das Ganze dann nochmal für “bar” und wir erhalten 9 und 10 als diejenigen Suffixe, die mit bar anfangen.

i	BWT	$T[\text{SA}[i].n - 1]$
0	a	\$
1	r	a\$
2	r	abarabara\$
3	d	abrababara\$
4	\$	abracadabrababara\$
5	r	acabadabrababara\$
6	c	adabrababara\$
7	b	ara\$
8	b	arabara\$
9	r	bara\$
10	a	babara\$
11	a	brababara\$
12	a	bracadabrababara\$
13	a	cadabrababara\$
14	a	dabrababara\$
15	a	ra\$
16	b	rababara\$
17	b	racadabrababara\$
18	a	rbara\$

Abbildung 3.7. Intervall $[\text{sp}_1, \text{ep}_1]$.

Zusammenfassung

Wir brauchen also nur C und R , um Abfragen zu Existenz und Anzahl eines Patterns machen zu können. Die Ausführungszeit ist in $O(m \cdot t_{\text{rank}})$, wobei t_{rank} die Ausführungszeit einer rank-Operation ist.

Als nächstes werden wir uns damit beschäftigen, wie wir die rank-Operation implementieren können. Wir werden dazu *wavelet trees*¹ verwenden.

3.7 Wavelet Trees

Wavelet Trees erlauben ein schnelles Berechnen der rank-Operation. Dazu wird in einem Baum codiert, ob ein bestimmter Buchstabe des Strings (hier des BWT) in der oberen oder der unteren Hälfte des Alphabets liegt. So werden die Buchstaben des BWT einem Kindknoten zugeordnet, wo auf dem jeweiligen Teilalphabet erneut eine

¹ Grossi & Vitter, 2003

Zweiteilung stattfindet. Dieser Prozess wiederholt sich so lange, bis in jedem Blatt nur Zeichen einer Art stehen.

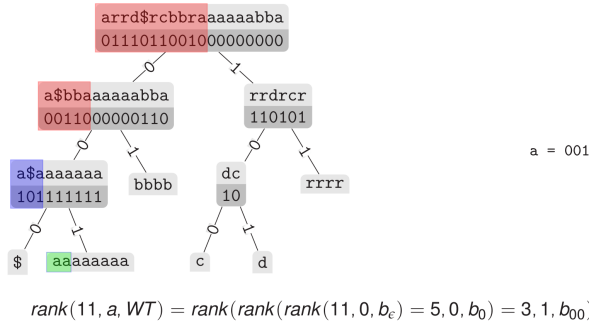


Abbildung 3.8. Wavelet Tree einer BWT und zugehörige Berechnung von $\text{rank}(11, a, \text{BWT})$.

Abfragen können auf einem Wavelet Tree in konstanter Zeit durchgeführt werden. Der Wavelet Tree selbst benötigt $o(n)$ viel Platz, genauer

$$O\left(\frac{n}{\log n} + \frac{n \log \log n}{\log n} + \sqrt{n} \log n \log \log n\right).$$

Die Konstruktion des Wavelet-Trees ist nicht zwingend an die Unterteilung des BWT zwei lexikographische Teilalphabete gebunden. Beispielsweise lässt sich eine Unterteilung in zwei Teilwörter auch durch die Häufigkeit der Buchstaben konstruieren, wodurch ein **Huffman-Wavelet-Tree** entsteht.

3.8 Exkurs — Succinct Data Structures

Eine extrem platzeffiziente Datenstruktur, **succinct data structure** genannt, benötigt nur wenig mehr Platz als die informationstheoretische untere Grenze, unterstützt allerdings Operationen zeiteffizient.

Sei L die informationstheoretische untere Schranke, die zur Repräsentierung einer Klasse von Objekten benötigt wird. Eine Datenstruktur, die Operationen trotzdem zeiteffizient unterstützt, heißt

- *implicit*, falls sie $L + O(1)$ Bits Platz braucht (also nur konstant mehr als die informationstheoretische untere Schranke, z.B. Heap),
- *succinct*, falls sie $L + o(L)$ Bits Platz braucht (also nur sublinear mehr als die informationstheoretische untere Schranke, z.B. Baum),
- *compact*, falls sie $O(L)$ Bits Platz braucht.

Binärbäume — succinct

Es gibt $C_n = \frac{1}{n+1} \binom{2n}{n}$ Binärbäume auf n Knoten. Um einen Binärbaum auf n Knoten speichern zu können, brauchen wir $\log C_n = 2n + o(n)$ bits.² Wir wollen folgende Operationen unterstützen:

- $\text{parent}(v)$
- $\text{leftchild}(v)$
- $\text{rightchild}(v)$

Eine mögliche Kodierung wäre, zu jedem Knoten des Baumes, der kein Blatt ist, so viele imaginäre Knoten hinzuzufügen, dass der jeweilige Knoten zwei Kinder hat (also entweder, 0, 1 oder 2 imaginäre Knoten). Diesen Prozess führt man durch, bis alle Blätter des Baumes dieselbe Tiefe haben. Wir können nun alle Knoten durchnummern und pro Knoten in einem Bit-Array speichern, ob der Knoten real (=1) ist oder nicht (=0).




Abbildung 3.9. Die schwarzen Knoten sind die realen Knoten des Baumes, die grauen die imaginären.

Die geforderten Operationen können hier sehr einfach implementiert werden:

- $\text{parent}(v) = \left\lfloor \frac{v-1}{2} \right\rfloor$ (für $v \neq \text{Wurzel}$)
- $\text{leftchild}(v) = 2v + 1$
- $\text{rightchild}(v) = 2v + 2$

Problem dieses Ansatzes ist, dass für einen Binärbaum mit einer Maximaltiefe d stets 2^d Bits benötigt werden.

Jacobson schlug 1989 einen besseren Algorithmus vor:

1. Alle Knoten des Binärbaums mit 1 markieren.
2. Kinder jedes Knotens im Baum mit imaginären Knoten auf 2 ergänzen.
3. Bit-Markierungen wie im vorhergehenden Algorithmus ablesen.

² Das kann mithilfe der Sterling-Approximation gezeigt werden.

3 Burrows-Wheeler-Transformation

Benötigt wird eine weitere Operation $\text{rank}(i, \text{type}, b)$, die für Knoten i des ergänzten Baums b zurückgibt, um den wievielten Knoten des Typs type es sich handelt. Wir erhalten folgendes Resultat:

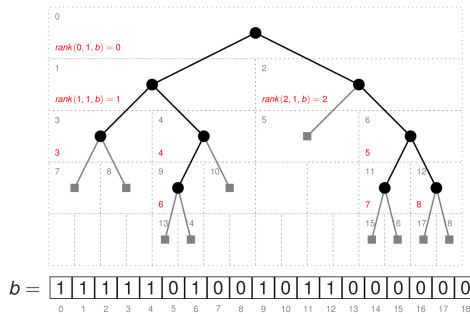


Abbildung 3.10. Jacobson-Kodierung eines Binärbaums.

Wir können hiermit also einen Binärbaum mit einem Bit-Array der Länge $2n + 1$ (mit n gesetzten Bits) repräsentieren. Die gewünschten Operationen funktionieren hier so:

- $\text{leftchild}(v) = 2\text{rank}(v) + 1$
- $\text{rightchild}(v) = 2\text{rank}(v) + 2$
- $\text{parent}(v) = \text{auch in konstanter Zeit möglich}^3$

Der totale Platzverbrauch inklusive rank ist also $2n + o(n)$ Bits.

Bäume — succinct: LOUDS

Die Abkürzung *LOUDS* steht für **level order unary degree sequence**.

Die Implementierung funktioniert so:

1. Füge über der Wurzel des Baums eine Pseudo-Wurzel hinzu und verbinde sie nur mit der alten Wurzel.
2. Der Ausgangsgrad wird zu jedem Knoten unär⁴ codiert dazugeschrieben.

Die **LOUDS-Sequenz** ist nun die Konkatenation der Knotenmarkierungen (sortiert nach Level).

³ Übungsaufgabe!

⁴ Ausgangsgrad x : x mal 0, hintendran immer noch eine 1.




Abbildung 3.11. Allgemeiner Baum mit Pseudo-Wurzel, Knotenmarkierungen und LOUDS-Sequenz.

Die Konstruktion verursacht, dass — abgesehen von der Wurzel — jeder Knoten zweimal in der LOUDS-Sequenz vorkommt: einmal als \emptyset in der Kinder-Liste seines Elternknotens und einmal als terminierende 1 in seiner eigenen Kinder-Liste.

Der gesamte Platzverbrauch hiervorn ist $2n + 1 + o(n)$ Bits. Außerdem lassen sich alle gewünschten Operationen in konstanter Zeit implementieren:

```
ISLEAF( $v$ )
 $id := \text{rank}(v, 0, \text{LOUDS})$ 
 $p := \text{select}(id + 2, 1, \text{LOUDS})$ 
return  $\text{LOUDS}[p - 1] == 1$ 
```

```
OUTDEGREE( $v$ )
if ISLEAF( $v$ ) then return 0
 $id := \text{rank}(v, 0, \text{LOUDS})$ 
return  $\text{select}(id + 2, 1, \text{LOUDS}) -$ 
        $\text{select}(id + 1, 1, \text{LOUDS}) - 1$ 
```

```
CHILD( $v, i$ )
if  $i < \text{OUTDEGREE}(v)$  then
    return  $\perp$ 
 $id := \text{rank}(v, 0, \text{LOUDS})$ 
return  $\text{select}(id + 1, 1, \text{LOUDS}) + i$ 
```

```
PARENT( $v$ )
if ISROOT( $v$ ) then
    return  $\perp$ 
 $pid := \text{rank}(v, 1, \text{LOUDS})$ 
return  $\text{select}(pid, 0, \text{LOUDS})$ 
```


4

Geometrische Algorithmen

Inhalt dieses Kapitels:

- Plane-Sweep-Algorithmus
- Konvexe Hülle
- Kleinste einschließende Kugel
- Range Search

4.1 Grundlegende Definitionen

Wir nennen $p \in \mathbb{R}^d$ einen **Punkt**. $p.i$ stelle die i -te Komponente von p dar. Für $d \in \{2, 3\}$ schreiben wir $p.x, p.y, p.z$ statt $p.1, p.2, p.3$.

Für zwei Punkte a, b definieren wir

$$\overline{ab} := \{\alpha \cdot a + (1 - \alpha) \cdot b : \alpha \in [0, 1]\}$$

als das **Segment** zwischen a und b .

Ein **Polygon** ist eine Menge an Segmenten, gegeben als Punktmenge $P = p_1, \dots, p_n$ mit $p_i \in \mathbb{R}^d, p_n = p_1, \overline{p_i, p_{i+1}}$ für $i = 1, \dots, n - 1$ ist der **Umriss** des Polygons.

Ist für alle $a, b \in P$ auch $\overline{ab} \in P$, so nennen wir P **konvex**.

4.2 Streckenschnitte

Bei diesem Problem sind n Strecken $S = \{s_1, \dots, s_n\}$ gegeben und wir wollen alle Schnittpunkte dieser, also $\bigcup_{s,t \in S} s \cap t$ berechnen.

Naiv lassen sich diese Streckenschnitte in $O(n^2)$ berechnen:

```
foreach {s,t} ∈ S do
  if s ∩ t ≠ ∅ then output {s,t}
```

Dieser Algorithmus ist für große Datenmengen offensichtlich zu langsam.

Idee ist nun, dass eine (waagerechte) **Sweep-Line** von oben nach unten läuft. Dabei speichern wir Segmente, die l schneiden, und finden deren Schnittpunkte. Invariante ist, dass Schnittpunkte oberhalb von l korrekt ausgegeben wurden.

Orthogonale Streckenschnitte

Zuerst betrachten wir die Vereinfachung, dass nur orthogonale Segmente (also parallel zur x - oder y -Achse existieren).

```
T := {} SortedSequence of Segment
invariant T stores vertical segments intersecting l
Q := sort(((y,s): ∃ hor-seg s at y ∨ ∃ ver-seg s starting/ending at y))
foreach (y,s) ∈ Q in descending order do
  if s is ver-seg and starts at y then T.insert(s)
  elif s is ver-seg and ends at y then T.remove(s)
  else // horizontal segment s = (x1,y)(x2,y)
    foreach t = (x,y1)(x,y2) ∈ T with x ∈ [x1,x2] do output {s,t}
```

Hier sind T und Q die einzigen komplexen Datenstrukturen, die wir benötigen, also sortierte Listen an Segmenten (T geordnet nach x -Wert, Q nach y).

`insert` und `remove` gehen in $O(\log n)$, die `rangeQuery` für ein Segment in $O(\log n + k_s)$ (bei k_s Schritten mit horizontalem Segment s). Insgesamt haben wir also

$$O(n \log n + \sum_s k_s) = O(n \log n + k).$$

Verallgemeinerung

Wir verallgemeinern jetzt den Spezialfall von oben, verwenden allerdings folgende Vereinfachungen: Es gebe keine horizontalen Segmente und Überschneidungen sind

immer nur zwischen zwei Segmenten, nicht mehr. Außerdem soll es keine Überlappungen geben, die Anzahl an Schnitten zwischen zwei Segmenten ist also immer entweder 0 oder 1.

Wir verwenden wieder T als nach x geordnete Liste der Strecken, die l schneidet. Außerdem verwenden wir *Ereignisse* — diese sind Änderungen von T , also das Starten und Enden von Segmenten sowie Schnittpunkte.

Einen Schnittest müssen wir nur dann durchführen, wenn zwei Segmente an einem Ereignispunkt in T benachbart sind.




Abbildung 4.1. Die grünen Punkte stellen die Ereignisse dar. Außerdem ist l zum Zeitpunkt der Ereignisse dargestellt.

Zur Implementierung brauchen wir nun einige Zusatzmethoden:

findNewEvent ermittelt, ob es einen Schnitt zwischen zwei Segmenten s und t gibt.

```
FINDNEWEVENT( $s, t$ )
if  $s$  and  $t$  cross at  $y' < y$  then
     $Q$ .insert( $(y', \text{intersection}, (s, t))$ )
```

Die Event-Handler werden kümmern sich um die Handhabung der drei möglichen Event-Types.

```
HANDLEEVENT( $y, \text{intersection}, (a, b), T, Q$ )
output( $s \cap t$ )
 $T$ .swap( $a, b$ )
prev := pred( $b$ )
next := succ( $a$ )
findNewEvent(prev,  $b$ )
findNewEvent( $a, next$ )
```

```
HANDLEEVENT( $y, \text{start}, s, T, Q$ )
 $h := T$ .insert( $s$ )
prev := pred( $h$ )
next := succ( $h$ )
findNewEvent(prev,  $h$ )
findNewEvent( $h, next$ )
```

```
HANDLEEVENT( $y, \text{finish}, s, T, Q$ )
 $h := T$ .locate( $s$ )
prev := pred( $h$ )
next := succ( $h$ )
 $T$ .remove( $s$ )
findNewEvent(prev, next)
```

Nun können wir den Algorithmus implementieren.

```

T := {} SortedSequence of Segment
invariant T stores relative order of segments intersecting l
Q := MaxPriorityQueue
Q := Q ∪ { (max{y, y'}, start, s) : s =  $\overline{(x, y)(x', y')}$  ∈ S }
Q := Q ∪ { (min{y, y'}, finish, s) : s =  $\overline{(x, y)(x', y')}$  ∈ S }
while Q ≠ ∅ do
  (y, type, s) := Q.deleteMax
  handleEvent(y, type, s, T, Q)

```

Dieser Algorithmus benötigt $O(n \log n)$ zur Initialisierung und $O((n + k) \log n)$ für die Event-Schleife, insgesamt also $O((n + k) \log n)$.

4.3 Konvexe Hülle

Wir werden uns in diesem Abschnitt mit dem folgenden Problem beschäftigen:

Gegeben sei eine Punktmenge $P = \{p_1, \dots, p_n\} \subset \mathbb{R}^2$. Gesucht ist ein konvexes Polygon C mit Eckpunkten $\in P$, sodass alle Punkte von P in C liegen.

Zuerst sortieren wir P lexikographisch. Das bedeutet, dass

$$p > q \iff p.x > q.x \vee (p.x = q.x \wedge p.y > q.y).$$

Wir berechnen ohne Einschränkung nur die obere Hülle, also die Hülle um die Punkte oberhalb von $\overline{p_1 p_n}$.




Abbildung 4.2. Obere Hülle.

Wir können beobachten, dass die obere Hülle ausschließlich Abbiegungen nach rechts macht (und die untere nur Abbiegungen nach links). Um damit arbeiten zu können müssen wir Abbiegungen definieren:

Definition 4.3.1 (Abbiegung). Für eine Punktmenge $P = \{p_1, \dots, p_n\}$ ist eine **Abbiegung nach rechts** an Stelle i vorhanden, falls p_{i+1} rechts von $\overline{p_{i-1} p_i}$ liegt.

Das konstruieren der oberen Hülle nennt sich auch **Graham's Scan**.¹

```

UPPERHULL( $p_1, \dots, p_n$ )
 $L := \langle p_n, p_1, p_2 \rangle$ : Stack of Point
invariant  $L$  is upper hull of  $\langle p_n, p_1, \dots, p_i \rangle$ 
for  $i := 3$  to  $n$  do
    while  $\neg \text{rightTurn}(L.\text{secondButlast}, L.\text{last}, p_i)$  do  $L.\text{pop}$ 
     $L := L \circ \langle p_i \rangle$ 
return  $L$ 

```

Der Algorithmus selbst läuft in $O(n)$, weswegen das Sortieren dominiert und das ganze in $O(n \log n)$ liegt.

4.4 Kleinste einschließende Kugel

In diesem Abschnitt ist eine Punktmenge $P := \{p_1, \dots, p_n\} \subset \mathbb{R}^d$ gegeben und eine Kugel K mit minimalem Radius gesucht, sodass $P \subset K$. Wir verwenden einen Algorithmus in $O(n)$ nach Welzl.²

Q sei zu Beginn leer. Wir fügen Punkte derart zu Q hinzu, dass durch die Punkte in Q ein Ball aufgespannt wird, in dem alle $p \in P$ liegen.

```

sEB( $P, Q$ )
if  $|P| = 0 \vee |Q| = d + 1$  then return ball( $Q$ )
 $x := p \in P$  picked at random
 $B := \text{sEB}(P \setminus \{x\}, Q)$ 
if  $x \in B$  then return  $B$ 
return sEB( $P \setminus \{x\}, Q \cup \{x\}$ )

```

4.5 Range Search

Beim **Range Search** (Bereichssuche) haben wir wieder eine Menge $P = \{p_1, \dots, p_n\} \subset \mathbb{R}^2$ gegeben. Wir erhalten als Anfrage nun ein achsenparalleles Rechteck

$$Q := [x, x'] \times [y, y'].$$

Gesucht ist nun entweder $P \cap Q$ (range reporting) oder $k := |P \cap Q|$ (range counting).

Wir werden range counting in $O(\log n)$ und range reporting in $O(k + \log n)$ lösen.

Dazu ist $O(n \log n)$ Vorverarbeitungszeit und $O(n)$ Platz notwendig.

¹ Graham 1972, Andrew 1979

² Welzl, 1991

Range Search im Eindimensionalen

Zuerst machen wir einen range search in einer Dimension. Dazu konstruieren wir im Voraus einen binären Suchbaum. Dieser codiert pro Blatt das größte Element des linken Teilbaums. So können die beiden Grenzen leicht gefunden werden.




Abbildung 4.3. Ermittlung des ersten Elements, das größer als 6 ist.

Range Search im Zweidimensionalen – Erster Ansatz

Ein naives Verfahren ist es, die Punkte aus P in zwei Arrays A_x und A_y zu speichern, wobei die Punkte in A_x nach x -Wert und in A_y nach y -Wert sortiert sind.

Man bestimmt nun

$$k_x := \text{count}(x_0, x_1) \text{ in } A_x \quad (\text{alle Punkte mit } x_0 < x < x_1) \text{ und}$$

$$k_y := \text{count}(y_0, y_1) \text{ in } A_y \quad (\text{alle Punkte mit } y_0 < y < y_1).$$

Nun müssen noch $\min\{k_x, k_y\}$ Punkte gematcht werden, um zu überprüfen, dass der jeweilige Punkt sowohl im x - als auch im y -Wert im Rechteck liegt.

Insgesamt braucht dieser Ansatz also $O(\log n) + O(\min \{k_x, k_y\})$ Zeit, ist also nicht wirklich brauchbar.

Range Search im Zweidimensionalen — Zweiter Ansatz

Wir konstruieren nun einen balancierten Binärbaum mithilfe der x -Koordinaten. Anschließend berechnen wir die $O(\log n)$ Teilbäume, die zusammen alle Punkte mit $x_0 \leq x \leq x_1$ enthalten. Nun müssen diese nur noch nach y -Koordinate gefiltert werden. Wir speichern dazu in jedem Knoten die Punkte ab, die in seinem Teilbaum liegen, sortiert nach y -Wert.

Insgesamt können wir so den Algorithmus auf $O(\log^2 n + k)$ drücken.

Mithilfe von Wavelet Trees lässt sich die Zeit auf $O(\log n)$ reduzieren.

5

Online-Algorithmen

Inhalt dieses Kapitels:

- Einführung in Online-Algorithmen
- Beispiel: Job-Scheduling
- Beispiel: Skiausleihe
- Beispiel: Speicherverwaltung
- Beispiel: Auswahl von Experten

Online-Algorithmen werden verwendet, wenn Eingabegrößen nicht im Vorhinein bekannt sind. Viele Algorithmen, die wir bisher diskutiert haben, benötigen Vorarbeitszeit, um optimale Ergebnisse liefern zu können, und sind daher nicht auf Probleme anwendbar, wo die Eingabe in serieller Natur vorliegt. Die bisher diskutierten Algorithmen werden daher auch **Offline-Algorithmen** genannt.

5.1 Übersicht

Wir werden uns im Folgenden Konzepte von Online-Algorithmen anhand von Beispielen anschauen. Zuerst definieren wir, was ein Online-Algorithmus formal ist.

- **Eingabe:** Folge von Anforderungen (*requests*)

$$\sigma = (r_1, \dots, r_n) \in R^n$$

- r_i muss auf Anforderung bearbeitet werden, es entsteht eine Antwort

$$a_i = g_i(r_1, \dots, r_i) \in A.$$

Es sind keine Informationen über die Zukunft verfügbar (r_{i+1}, \dots) . Antworten sind unwiderruflich.

Der konkrete Algorithmus ist also durch g_1, \dots eindeutig festgelegt.

- **Kosten** $\text{cost}_n : R^n \times A^n \rightarrow \mathbb{R}_{\geq 0}$
- **Ausgabe** für $\sigma \in R^n$ ist also

$$\text{alg}[\sigma] = (g_1(r_1), g_2(r_1, r_2), \dots, g_n(r_1, \dots, r_n)) \in A^n$$

und die Kosten

$$\text{alg}(\sigma) = \text{cost}_n(\sigma, \text{alg}[\sigma])$$

Kompetitive Analyse

Um einschätzen zu können, wie gut ein Online-Algorithmus ist, vergleichen wir ihn mit einem optimalen Offline-Algorithmus — das ist die **Kompetitive Analyse** dieses Online-Algorithmus.

Definition 5.1.1 (c -kompetitiv). Ein Online-Algorithmus ist für ein Optimierungsproblem auf Input σ **c -kompetitiv**, falls es einen Offline-Algorithmus OPT gibt, der nach einem Kostenmaß $\text{OPT}(\sigma)$ eine Optimallösung berechnen kann, sodass für den betrachteten Online-Algorithmus ALG und alle Eingabesequenzen σ gilt:

$$\text{ALG}(\sigma) \leq c \cdot \text{OPT}(\sigma) + \alpha.$$

Ist die zusätzliche Konstante $\alpha \leq 0$, dann heißt ALG **strikt c -kompetitiv**.

Unterschied ist, dass man bei nicht-strikter kompetitivität Ausnahmen erlaubt.

Wir können nun den **Wettbewerbsfaktor** (*competitive ratio*) für den Algorithmus ALG definieren als

$$c_{\text{alg}} = \sup \left\{ \frac{\text{alg}(\sigma)}{\text{opt}(\sigma)} : \sigma \in R^+ \right\}.$$

Ist alg ein strikt c -kompetitiver Online-Algorithmus und

$$C = \{c : \text{alg ist strikt } c\text{-kompetitiv}\},$$

so ist

$$c_{\text{alg}} = \inf C \quad \text{und} \quad c_{\text{alg}} \in C.$$

Im Folgenden geben wir eine kurze Übersicht über die Beispiele, die wir im Folgenden behandeln werden.

Job-Scheduling

Dieses Beispiel ist dem Beispiel im Kapitel “Approximationsalgorithmen” sehr ähnlich. Wir haben

- **Maschinen** M_1, \dots, M_m
- **Anfrage:** Job J_i , benötigt Zeit $t_i \geq 0$
- **Antwort:** Zuordnung von J_i zu M_j

Wieder stellt sich die Frage, wie sich der Makespan (also das Intervall zwischen Start und Fertigstellen der letzten Maschine) minimieren lässt. Diese Entscheidung muss hier für jedes J_i ohne Kenntnis über die zukünftigen Jobs passieren.

Skiausleihe

Die Situation ist hier folgende: Man befinde sich im Skiurlaub und solange das Wetter gut ist, lautet jeden Morgen die **Anforderung** “Ski ausleihen!”. Sobald das Wetter allerdings schlecht ist, lautet die **Anforderung** “Heimfahren!”.

Es sind zwei **Antworten** möglich:

- Ski für einen Tag ausleihen: Kosten k Euro
- Ski kaufen: Kosten K Euro ($K \gg k$)

Was muss nun getan werden, um die Gesamtkosten klein zu halten? Diese Entscheidung muss ohne Kenntnis des zukünftigen Wetters gemacht werden!

Speicherverwaltung

“Kosten minimieren” bedeutet im Speicherverwaltungskontext meist, die Anzahl an Cache Misses zu minimieren. Welche Verdrängungsstrategie minimiert die Kosten hier am besten? Und wie kann man am besten zu verdrängende Seiten auswählen, ohne Kenntnis über zukünftige Anforderungen zu haben?

Auswahl von Experten

Hier gibt es mehrere Runden, jede läuft wie folgt ab:

1. Jeder von n Experten gibt zu einer Frage eine Ja/Nein-Empfehlung ab. Diese sind im Allgemeinen nicht richtig.
2. Man trifft seine eigene Ja/Nein-Entscheidung zu derselben Fragestellung.
3. Es wird mitgeteilt, welche Entscheidung richtig gewesen wäre.

Wie lässt sich hier die Anzahl an Fehlentscheidungen minimieren?

Selbstorganisierende Datenstrukturen

Hier haben wir eine einfach verkettete Liste und erhalten als **Anforderung** das Element x in der Liste. Die dabei entstehenden Kosten sind x . Als **Reaktion** kann entweder

- ohne weitere Kosten das angefragte Element weiter nach vorne gerückt werden, oder
- mit Kosten von 1 zwei aufeinanderfolgende Elemente vertauscht werden.

Welche Listen-Verwaltung minimiert hier die Kosten? Wie kann ohne Kenntnis über zukünftige Anforderungen sinnvoll umgeordnet werden?

5.2 Job-Scheduling

Wir nehmen den listScheduling-Approximationsalgorithmus und bauen ihn in einen Online-Algorithmus um:

```
LISTSCHEDULING( $n, m, t_1 \dots t_n$ )
  each  $L_i := 0$     // load of machine  $1 \leq i \leq m$ 
  each  $S_j := 0$     // machine for job  $1 \leq j \leq n$ 
  for each  $j$  in range( $1, n$ ) do
    pick  $k$  from  $\{i : L_i \text{ is currently minimal}\}$ 
     $S_j := k$ 
     $L_k := L_k + t_j$ 
  return  $S$ 
```

Frühere Analysen ergeben, dass der Wettbewerbsfaktor höchstens 2 ist. Der Online-Algorithmus sieht nun so aus:

```

LISTSCHEDULING(  $m$  )
each  $L_i := 0$  // load of machine  $1 \leq i \leq m$ 

for each  $t_j$  in  $\sigma$  do
  pick  $k$  from  $\{i : L_i \text{ is currently minimal}\}$ 
   $a_j := k$ 
   $L_k := L_k + t_j$ 
  assign job to machine  $a_j$ 

```

5.3 Skiausleihe

Wir haben oben bereits diskutiert, was hier das Problem ist.

Die Optimalkosten sind offensichtlich

- Falls Urlaubsdauer $t \leq \frac{K}{k}$ Tage: t mal ausleihen \Rightarrow Kosten tk
- Falls Urlaubsdauer $t > \frac{K}{k}$ Tage: Ski sofort kaufen \Rightarrow Kosten K

Der Wettbewerbsfaktor ist hier 2. Optimal ist es, an Tag $\frac{K}{k}$ die Ski zu kaufen.

5.4 Speicherverwaltung

Wir werden uns die folgenden Speicherverwaltungsprobleme anschauen:

- *Offline* (lfd ist optimal)
- *Deterministisch* (bestenfalls k -kompetitiv)
- *Deterministisch*: lru ist k -kompetitiv
- *Resource Augmentation*: (h, k) -Seitenwechsel
- *Randomisiert* (randMark ist $2H_k$ -kompetitiv)

Wir betrachten hier stets einen Speicher der Größe K und einen Cache der Größe k ($K \gg k$).

Offline — lfd ist optimal

lfd (*longest forward distance*) verdrängt den Eintrag, der am weitesten in der Zukunft benötigt wird. Dieser Algorithmus ist offensichtlich optimal aber auch offensichtlich nicht möglich.

3	1	5	3	2	4	1
1	4	2				
3	1	5	3	2	4	1
1	3	2				

Abbildung 5.1. Eingabe und Cache vor und nach Bearbeitung der ersten Anforderung. Es wird die 4 ersetzt, weil sie erst am weitesten in der Zukunft wieder benötigt wird.

Deterministisch — bestenfalls k -kompetitiv

Die vier üblichen Algorithmen sind

- fifo (*first in first out*),
- lifo (*last in first out*),
- lru (*least recently used*),
- lfu (*least frequently used*).

lifo und lfu sind nicht kompetitiv, lru und fifo sind k -kompetitiv. In der Praxis wird üblicherweise lru verwendet.

Es gilt folgender Satz:

Satz 5.4.1. Jeder deterministische Online-Algorithmus für das Seitenwechselproblem mit Cachegröße k hat einen Wettbewerbsfaktor $c \geq k$. k ist also eine untere Schranke für den Wettbewerbsfaktor.

Deterministisch: lru ist k -kompetitiv

Wir können zeigen, dass lru k -kompetitiv ist.

Resource Augmentation

Wir betrachten das (h, k) -Seitenwechselproblem: hier wird der Online-Algorithmus alg_k mit der Cachegröße k mit lfd_h mit Cachegröße $h < k$ verglichen.

Wir benötigen folgende Definition:

Definition 5.4.2. Ein Online-Algorithmus heißt **konservativ**, falls er bei Andordefolgen mit höchstens k verschiedenen Seiten höchstens k Cache-Misses hat. Beispiele hierfür sind lru und fifo.

Es gilt:

Jeder konservative Online-Algorithmus ist $\frac{k}{k-h+1}$ -kompetitiv.

Randomisiert: randMark ist $2H_k$ -kompetitiv

Bei einem randomisierten Online-Algorithmus zur Speicherverwaltung ist die Zahl der Cache-Misses eine *Zufallsvariable*

$$f_R(r_1, \dots, r_n).$$

Hier sind gegebenenfalls andere Sichtweisen auf c -kompetitivität sinnvoll.

Zur Analyse verwenden wir sogenannte **Widersacher**. Diese bekommen als Eingabe die gewünschte Länge n und R und erzeugen eine "schlimme" Anforderungsfolge der Länge n . Diese müssen sie aber auch selbst verarbeiten.

Wir unterscheiden folgende Widersachertypen:

- **unwissender Widersacher** W (*oblivious adversary*): kein Wissen über erzeugte Zufallsbits, erzeugt für (R, n) immer gleiches (r_1, \dots, r_n) .
- **adaptiver Widersacher** W^I (*adaptive adversary*): arbeitet gegen eine konkrete Abarbeitung von R , kennt die von R bei der Abarbeitung von (r_1, \dots, r_i) erzeugten Zufallsbits und folglich auch immer den aktuellen Cache-Zustand von R .

Wir werden im Folgenden nur unwissende Widersacher analysieren und vergleichen sie mit $\text{opt}(r_1, \dots, r_n)$.

Definition 5.4.3. R ist c -kompetitiv gegen unwissende Widersacher, wenn es ein von n unabhängiges b gibt, sodass für jede Anforderungsfolge (r_1, \dots, r_n) gilt:

$$\mathbb{E}[f_R(r_1, \dots, r_n)] - c \cdot \text{opt}(r_1, \dots, r_n) \leq b.$$

Wir betrachten nun den randMark-Algorithmus.¹

```

⟨Cache: cache[i], Markierungsbits mark[i], 1 ≤ i ≤ k⟩
for i := 1 to k do mark[i] := 0 // alle Markierungen auf 0
while ∃ weitere Anforderungen do
  r := nächste Anforderung
  if memory[r] ∉ cache then
    if ∀ mark[i] ≡ 1 then ∀ mark[i] := 0 // alles 1 → neue Phase → alles 0
    i := zufälliges j mit mark[j] ≡ 0
    cache[i] := memory[r]
  else i := Index mit cache[i] ≡ memory[r]
mark[i] := 1

```

Dieser Algorithmus ist $2H_k$ -kompetitiv gegen unwissende Widersacher.

¹ Fiat et al., 1991

5.5 Auswahl von Experten

Es gibt mehrere Runden mit folgender Struktur:

1. Jeder von n Experten gibt zu einer Frage eine Ja/Nein-Empfehlung ab. Diese sind im Allgemeinen nicht richtig.
2. Man trifft seine eigene Ja/Nein-Entscheidung zu derselben Fragestellung.
3. Es wird mitgeteilt, welche Entscheidung richtig gewesen wäre.

Ziel ist:

- **Anforderung:** k -Tupel aus Ja/Nein-Empfehlungen der Experten
- **Antwort:** Eigene Ja/Nein-Entscheidung
- **Kosten:** Anzahl eigener Fehlentscheidungen
- **Ziel:** Die eigenen Kosten sollen möglichst nah an den Kosten der besten Experten liegen

Es ist leicht einzusehen, dass immer die Antwort des Experten zu wählen, der bisher am meisten korrekte Antworten produziert hat, schlecht ist — man kann eine Expertenmenge derart konstruieren, dass diese Strategie immer irrt.

Weighted Majority Algorithm

Der **Weighted Majority Algorithm** weist zu Beginn jedem Experte i ein Gewicht $w_i := 1$ zu.

In jeder Runde wird die eigene Entscheidung nun folgendermaßen konstruiert:

1. Experten geben Empfehlungen $x_i \in \{\text{ja}, \text{nein}\}$
2. Eigene Entscheidung fällen:

$$\begin{cases} \text{ja,} & \text{falls } \sum_{i, x_i \equiv \text{ja}} w_i \geq \sum_{i, x_i \equiv \text{nein}} w_i \\ \text{nein,} & \text{falls } \sum_{i, x_i \equiv \text{ja}} w_i < \sum_{i, x_i \equiv \text{nein}} w_i \end{cases}$$

3. Expertengewichte anpassen:

$$w_i^{t+1} = \begin{cases} w_i^t, & \text{falls } x_i \text{ richtig war} \\ \frac{w_i^t}{2}, & \text{falls } x_i \text{ falsch war} \end{cases}$$

wma ist $\frac{1}{\log_2(4/3)}$ -kompetitiv. Genauer:

$$\text{wma}(\sigma) \leq \frac{1}{\log_2(4/3)} (\text{optExpert}(\sigma) + \log_2 k).$$

Verallgemeinerung

Wir betrachten nun nicht mehr nur den Fall, dass Antworten richtig oder falsch sein können, sondern gewichten sie mit Faktoren zwischen 0 und 1. In der t -ten Runde läuft ab:

1. **Experten:** geben Empfehlungen x_1, \dots, x_k
2. Eigene Wahl der Empfehlung
3. Mitteilung, welche Entscheidung richtig gewesen wäre
4. Beurteilung der Empfehlungen durch "Noten" $c_i^t \in [0, 1]$
5. **Kosten:** Note der gewählten Empfehlung

Wir verwenden hierfür einen randomisierten Algorithmus $\text{randWMA}_\varepsilon$:

- Initial:
 - Es sei $\varepsilon \in (0, \frac{1}{2})$
 - Experte i hat Gewicht w_i
 - alle $w_i := 1$
- In jeder Runde t :
 1. wähle Empfehlung von Experte i mit Wahrscheinlichkeit

$$p_i = \frac{w_i}{\sum_1^k w_i}$$

2. Benotung
3. setze jedes $w_i := w_i(1 - \varepsilon c_i^t)$

Ist k die Anzahl der Experten und $0 < \varepsilon < \frac{1}{2}$ und $\text{randWMA}_\varepsilon$ nach einer Anzahl an Runden Gesamtkosten von K hat und die besten Experten Empfehlungen mit (minimalen) Gesamtkosten K_{opt} gegeben haben, so ist

$$K \leq (1 + \varepsilon) \cdot K_{\text{opt}} + \frac{\ln n}{\varepsilon}.$$